

Pengisian poin C sampai dengan poin H mengikuti template berikut dan tidak dibatasi jumlah kata atau halaman namun disarankan ringkas mungkin. Dilarang menghapus/modifikasi template ataupun menghapus penjelasan di setiap poin.

C. HASIL PELAKSANAAN PENELITIAN: Tuliskan secara ringkas hasil pelaksanaan penelitian yang telah dicapai sesuai tahun pelaksanaan penelitian. Penyajian meliputi data, hasil analisis, dan capaian luaran (wajib dan atau tambahan). Seluruh hasil atau capaian yang dilaporkan harus berkaitan dengan tahapan pelaksanaan penelitian sebagaimana direncanakan pada proposal. Penyajian data dapat berupa gambar, tabel, grafik, dan sejenisnya, serta analisis didukung dengan sumber pustaka primer yang relevan dan terkini.

I. TEORI DAN LITERATUR PENDUKUNG

A. Teori Keagenan di Industri Asuransi

Pemisahan kepemilikan dan manajemen menciptakan ruang untuk moral hazard dan seleksi yang merugikan, yaitu manajer memiliki insentif jangka pendek untuk mempercantik kinerja Perusahaan. Beberapa tindakan yang dapat diambil termasuk kurang memesan klaim, mengejar imbal hasil tinggi pada aset berisiko (yang menciptakan ketidakcocokan aset-liabilitas), atau menunda pengakuan kerugian, yang pada akhirnya meningkatkan kemungkinan *kesulitan keuangan* [1] [2]. Pada perusahaan asuransi, risiko ini lebih tajam karena kewajiban jangka panjang dan tidak pasti (mortalitas, morbiditas, risiko ekor), sehingga kesalahan kecil dalam asumsi dapat berdampak signifikan pada solvabilitas.

Dalam praktiknya, biaya keagenan ditekan melalui kombinasi tata kelola internal, desain insentif, struktur kepemilikan, dan disiplin eksternal. Tata kelola internal dipastikan melalui konfigurasi dewan yang tepat, ditandai dengan proporsi komisaris independen yang memadai, keahlian keuangan/aktuarial, dan komite audit yang intensif. Hal ini dapat memperkuat fungsi pemantauan, yang mengarah pada perkiraan cadangan yang lebih konservatif dan pelaporan risiko yang lebih andal [2] [3]. Desain insentif dan kontrak juga menentukan arah perilaku, misalnya, melalui skema sensitivitas kinerja gaji yang sehat, klausul clawback, dan kebijakan selera risiko yang menghubungkan bonus dengan metrik risiko. Struktur kepemilikan dapat menyelaraskan kepentingan, misalnya, melalui kepemilikan manajerial. Namun, tanpa pengawasan yang memadai, hal itu dapat menyebabkan pengakuan dan keputusan risiko yang kurang disiplin. Disiplin eksternal dari lembaga pemeringkat, analis pasar, dan regulator, melalui pengujian RBC/SCR, proses ORSA, dan pengawasan berkala, dapat menciptakan tekanan yang kredibel bagi manajemen untuk menjaga kualitas cadangan, transparansi pelaporan, dan konsistensi strategi risiko [3] [4].

B. Prediksi Kebangkrutan

Prediksi kebangkrutan perusahaan asuransi telah muncul sebagai masalah penting dalam penelitian keuangan, karena perlu untuk melindungi pelanggan dan pemangku kepentingan lainnya serta meminimalkan biaya yang terkait dengan kebangkrutan perusahaan asuransi. Sebagian besar metode yang digunakan di masa lalu untuk memprediksi kegagalan bisnis perusahaan asuransi adalah teknik statistik tradisional yang menggunakan rasio keuangan sebagai variabel penjelasan. Beberapa peneliti, misalnya, menggunakan regresi logistik dan analisis diskriminasi dengan penjelasan rasio keuangan dalam memprediksi kegagalan perusahaan asuransi [5], [6]. Metode ini juga digunakan untuk memprediksi kegagalan perusahaan non-asuransi ([6] [7] [8], [9], [10], [11]).

Model logistik juga digunakan untuk memprediksi hasil di bidang lain di luar asuransi dan kebangkrutan. Misalnya studi yang dilakukan oleh [12] yang mengkaji pengaruh Indeks Persepsi Tata Kelola Perusahaan (CGPI) dan Karakteristik Obligasi terhadap Peringkat Obligasi menggunakan regresi logistik ordinal. Tata Kelola Perusahaan diyakini dapat meningkatkan kualitas pengelolaan perusahaan, yang pada gilirannya akan meningkatkan kinerja Perseroan.

Dalam perkembangan selanjutnya, metode Neural Network banyak digunakan dalam memprediksi kegagalan atau kebangkrutan perusahaan asuransi ([13] [14]), [15], [7], [8], [9]). [16] juga menemukan bahwa Jaringan Saraf Buatan (ANN) mencapai akurasi 98,35%, menunjukkan kinerja terbaik dalam klasifikasi di antara model *penambangan data* lainnya. Metode Neural Network juga digunakan untuk memprediksi hasil di bidang di luar kegagalan bisnis.

Studi lain memperkirakan kerugian di lima perusahaan asuransi yang menggunakan machine learning ([17] Mereka menemukan bahwa perkiraan kerugian yang dihasilkan oleh pembelajaran mesin lebih unggul daripada perkiraan manajerial aktual yang dilaporkan dalam laporan keuangan. Pada perusahaan asuransi kewajiban properti di Mesir, jaringan saraf buatan (ANN) telah terbukti efektif dalam menilai kinerja/solvabilitas berdasarkan rasio keuangan [18] Studi klasik pada data perusahaan asuransi AS juga menunjukkan bahwa jaringan saraf dapat menangkap hubungan non-linier dan mencapai akurasi tinggi dalam peringatan dini [9] Di seluruh

industri, tinjauan sistematis terbaru (2012–2023) menemukan adopsi cepat ML/AI (SVM, gradient boosting, ensemble, dan deep learning) untuk prediksi kebangkrutan. Namun, masalah interpretabilitas, *pergeseran data*, dan validitas eksternal tetap penting untuk implementasi kebijakan/peraturan, menjaga relevansi model parametrik (misalnya, logit multinomial) yang lebih stabil dan transparan [19]

II. SAMPEL DAN FITUR DATA

Data dalam penelitian ini mencakup 148 perusahaan asuransi dengan rentang laporan keuangan dari tahun 2015 hingga 2024. Data tersebut bersumber dari laporan keuangan dan laporan tahunan yang diperoleh dari publikasi online perusahaan asuransi.

Data penelitian ini bersifat tidak seimbang (imbalanced), di mana jumlah perusahaan yang tergolong Potentially Bankrupt lebih sedikit dibandingkan dengan kategori Grey Area dan Safe Zone, sehingga diperlukan penanganan khusus sebelum proses pemodelan. Jenis klasifikasi yang diterapkan pada variabel target memiliki tiga kategori nominal yaitu Potentially Bankrupt (0), Grey Area (1), and Safe Zone (2) dengan distribusi Kategori 0 sebanyak 391 data, Kategori 1 sebanyak 213 data, dan Kategori 2 sebanyak 567 data.

Ketidakseimbangan data dapat menyebabkan model cenderung memprediksi kelas mayoritas sehingga menurunkan kemampuan sistem dalam mendeteksi perusahaan yang berisiko insolvency. Untuk mengatasi hal tersebut, pada metode Machine Learning penelitian ini menerapkan metode Synthetic Minority Oversampling Technique (SMOTE). SMOTE bekerja dengan membangkitkan sampel sintetis baru pada kelas minoritas melalui interpolasi antar titik data yang berdekatan, sehingga meningkatkan representasi kelompok perusahaan insolvent tanpa menghilangkan atau menggandakan data secara langsung. Pendekatan ini dipilih karena memiliki efektifitas yang tinggi dalam meningkatkan sensitivitas model terhadap kelas minoritas. Dengan demikian, dataset yang digunakan dalam pemodelan menjadi lebih seimbang dan diharapkan meningkatkan kemampuan model dalam mengidentifikasi risiko insolvency secara lebih akurat dan stabil.

III. ALGORITMA PEMODELAN

Pemodelan dilakukan menggunakan bahasa pemrograman Python di lingkungan Google Colab untuk membandingkan kinerja Multinomial Logistic Regression (MLR), Neural Network (NN), dan Machine Learning. Pada kelompok Machine Learning, beberapa algoritme diterapkan secara otomatis dan dievaluasi untuk melihat variasi performa yang dihasilkan. Setiap model dinilai menggunakan metrik akurasi, presisi, recall, F1-Score, serta analisis confusion matrix, sehingga proses evaluasi tidak hanya menilai ketepatan prediksi secara keseluruhan, tetapi juga konsistensi performa antar kelas. Dengan demikian, perbandingan ketiga pendekatan ini memberikan gambaran mengenai perbedaan karakteristik dan efektivitas model dalam memprediksi kondisi kesehatan perusahaan.

A. Regresi Logistik Multinomial

Multinomial Logistic Regression (MLR) digunakan untuk memodelkan hubungan antara variabel-variabel keuangan dengan status kesehatan perusahaan. Langkah yang dilakukan seperti pada Gambar berikut.

Persiapan Environment dan data $\Rightarrow$ Penskalaan Fitur $\Rightarrow$ Pemodelan (MLE Logit) dan Pelatihan $\Rightarrow$ Ekstraksi dan Interpretasi Koefisien

Model ini mengestimasi koefisien (β) regresi untuk setiap kategori, sehingga diperoleh probabilitas peluang perusahaan masuk dalam masing-masing kelas. Kelebihan MLR terletak pada kemampuan interpretasinya yang jelas, karena kontribusi setiap variabel prediktor dapat diidentifikasi secara langsung. Indikator tersebut selanjutnya digunakan untuk menentukan kategori kondisi keuangan perusahaan menggunakan fungsi berikut:

$$BP = f(\text{liquidity}, \text{solvability}, \text{rentability}, \text{corporate governance structure}, \text{control variable})$$

BP adalah Prediksi Kebangkrutan berdasarkan perhitungan Altman Z Score dengan tiga kelompok prediksi. Fungsi persamaan akan diuji menggunakan: (1) Regresi logistik multinomial; (2) Jaringan Saraf, dan (3) Pembelajaran Mesin.

Regresi logistik multinomial sebagai perpanjangan dari biner (regresi logistik dengan dua kategori) dipilih karena variabel dependen memiliki 3 kategori dengan persamaan sebagai berikut.

$$\ln \frac{P(Y_i = \text{save zone})}{P(Y_i = \text{distress zone})} = a + b_1 \text{Liq} + b_2 \text{Sol} + b_3 \text{Corp Gov Stru} + b_4 \text{control variable} + e$$

$$\ln \frac{P(Y_i = \text{grey zone})}{P(Y_i = \text{distress zone})} = a + b_1 \text{Liq} + b_2 \text{Sol} + b_3 \text{Corp Gov Stru} + b_4 \text{control variable} + e$$

Kategori 0 ditetapkan sebagai kategori *ref* karena merepresentasikan risiko tertinggi dan menjadi dasar pembandingan bagi kategori lainnya. Dengan acuan ini, model membentuk dua fungsi logit terpisah yang dihitung menggunakan Maximum Likelihood Estimation (MLE). MLE dibangun menggunakan statsmodels.MNLogit dimana MNLogit merupakan class yang terdapat dalam library statsmodels yang berperan pada Multinomial Logistic Regression untuk memodelkan variabel target kategorikal (lebih dari 2 kelas). Class MNLogit yang bertujuan untuk menemukan β yang memaksimalkan Likelihood. Setiap koefisien β menunjukkan perubahan log-peluang suatu perusahaan masuk ke kategori lain dibandingkan dengan kategori acuan saat variabel prediktor meningkat satu unit. Pembagian data sebesar 80% untuk pelatihan dan 20% data untuk pengujian.


B. Artificial Neural Network

Neural Network (NN) diterapkan untuk menangkap pola hubungan non-linear yang tidak dapat dijelaskan secara sempurna oleh pendekatan regresi. Pengembangan model dilakukan dengan penentuan jumlah neuron dalam hidden layer serta penggunaan fungsi aktivasi non-linear untuk memperkuat proses pembelajaran. Model ini melakukan penyesuaian bobot selama pelatihan sehingga mampu mengidentifikasi pola kompleks dalam data keuangan. NN bersifat black-box, sehingga interpretasi mengenai kontribusi masing-masing variabel menjadi lebih terbatas. Langkah yang dilakukan seperti pada Gambar berikut.

Data Preprocessing $\Rightarrow$ Model Architecture Construction $\Rightarrow$ Model Compilation $\Rightarrow$ Model Training (Fitting) $\Rightarrow$ Evaluation

Model Artificial Neural Network menggunakan Hyperparameter Optimization (HPO) berbasis Optuna. Data dibagi dengan pembagian 80% data pelatihan dan 20% data pengujian. Model Artificial Neural Network dibangun dengan Keras Sequential API, yang memungkinkan pembentukan jaringan bertingkat dengan komponen utama Dense Layer, Dropout, Batch Normalization, dan Output Layer Softmax. Optuna secara otomatis menyesuaikan parameter penting seperti jumlah hidden layer, neuron, fungsi aktivasi, dropout, dan learning rate untuk mencapai performa terbaik.

Arsitektur Artificial Neural Network memiliki tiga hidden layers dengan kombinasi 155, 218, dan 75 neuron serta total 54.352 trainable parameters. Struktur ini efektif menyeimbangkan kompleksitas dan kinerja. Output layer dengan tiga neuron menghasilkan probabilitas untuk masing-masing kelas risiko, sehingga model mampu memprediksi kondisi keuangan perusahaan secara otomatis, adaptif, dan akurat.



Gambar arsitektur Artificial Neural Network

C. Pemodelan Klasifikasi Ensemble Machine Learning.

Pada pendekatan Machine Learning (ML), penelitian ini mengevaluasi beberapa model pembelajaran seperti Random Forest, Support Vector Machine, dan Gradient Boosting. Setiap model dilatih menggunakan prosedur cross-validation dan hyperparameter tuning untuk memperoleh performa yang optimal. Selanjutnya dilakukan evaluasi menggunakan metrik akurasi, presisi, recall, F1-score, dan analisis confusion matrix. Dari beberapa algoritme tersebut, hanya model dengan kinerja terbaik yang disajikan. Proses pengembangan menggunakan seperti alur pada Gambar berikut.

Data Acquisition & Understanding $\Rightarrow$ Data Preprocessing (SMOTE) $\Rightarrow$ Feature Optimization $\Rightarrow$ Modeling & Tuning $\Rightarrow$ Evaluation $\Rightarrow$ Validation & Comparison

IV. HASIL PENELITIAN

A. Statistik Deskriptif

Statistik Deskriptif disajikan pada tabel berikut. Data dalam penelitian ini mencakup 148 perusahaan asuransi dengan rentang periode laporan keuangan tahun 2015 hingga 2024. Data dikumpulkan dari laporan keuangan tahunan yang dipublikasikan oleh masing-masing perusahaan. Setelah proses pembersihan data, seperti penghapusan entri yang tidak lengkap atau tidak konsisten, jumlah total observasi yang digunakan dalam analisis adalah 1.171 baris data. Data penelitian ini bersifat tidak seimbang (imbalanced), di mana jumlah perusahaan yang tergolong Potentially Bankrupt lebih sedikit dibandingkan dengan kategori Grey Area dan Safe Zone, sehingga diperlukan penanganan khusus sebelum proses pemodelan.

	Number	Mean	Minimum	Maximum
Current_Ratio	1171	3,723116994	0,04	335,19
Cash_Ratio	1171	1,122553373	0	289,77
DAR	1171	0,610017079	0	1,5
DER	1171	0,995115286	-3976,61	1641,97
NPM	1171	0,035772844	-8,15	1,76
ROA	1171	0,024158839	-0,34	10,39
ROE	1171	-0,365678907	-374,19	4,32
Majority_Ownership	1171	0,741887276	0	1
Independent_Commissioner	1171	1,822374039	0	5
Insider_Ownership	1171	0,026482152	0	1
BoC_Size	1171	3,450042699	0	8
BoC_Education	1171	3,35439795	0	28
TMT_Size	1171	6,993168232	0	15
TMT_Education	1171	6,211784799	0	43
Total_Assets	1171	5883031452666,33	53760200000,0	71757702000000,00
Revenue_Growth	1171	2,054406234	-2,8691	545,3648
Z_Score	1171	2,983542699	-9,627	154,7446

B. Perbandingan Precision, Recall, dan F1-Score setiap kategori

1. Multinomial Logistic Regression (MLR)

Model MLR menunjukkan performa yang baik pada kelas 0 (Potentially Bankrupt) dan 2 (Safe Zone) dengan F1-Score masing-masing 0.80 dan 0.86, yang menandakan kemampuan model dalam membedakan kondisi keuangan perusahaan yang memiliki variabel-variabel prediktor dengan pola yang berbeda. Namun, performa MLR sangat rendah pada kelas 1 (Grey Area), dengan Recall hanya 0.14, menghasilkan F1-Score sebesar 0.22. Hal ini mengindikasikan bahwa perusahaan yang berada pada kondisi transisi atau tidak stabil sering salah diklasifikasikan ke kelas lain. Kondisi ini dapat terjadi karena ciri keuangan kelas Grey Area lebih ambigu, sehingga model linear seperti MLR tidak cukup fleksibel dalam menangkap variabilitasnya.

2. Artificial Neural Network

Model Artificial Neural Network menunjukkan performa paling stabil dan seimbang di seluruh kelas. Kelas 2 (Safe Zone) menunjukkan nilai Precision, Recall, dan F1-Score yang sangat tinggi (0.89), menandakan bahwa Artificial Neural Network sangat efektif mengenali perusahaan sehat. Pada kelas 0 (Potentially Bankrupt), Artificial Neural Network memberikan F1-Score 0.56, sementara pada kelas 1 (Grey Area) mencapai 0.83, menunjukkan bahwa Artificial Neural Network mampu menangkap pola non-linear yang membedakan kondisi grey area, yang sebelumnya sulit dikenali oleh MLR. Dengan demikian, Artificial Neural Network menjadi model yang paling seimbang dalam mengenali semua kondisi kesehatan perusahaan.

3. Machine Learning

Model Random Forest menunjukkan kinerja klasifikasi yang kuat pada kategori Grey Area (1) dan Safe Zone (2), namun masih terbatas dalam mengidentifikasi kategori Potentially Bankrupt (0). Pada kategori 0, nilai presisi sebesar 0.75 dan recall 0.41 menghasilkan F1-Score 0.53, yang menunjukkan bahwa model cukup tepat dalam memprediksi ketika memilih kategori ini, namun sering gagal mengenali perusahaan yang benar-benar berada pada kondisi berisiko tinggi. Sebaliknya, pada kategori Grey Area (1), performa meningkat signifikan dengan recall 0.95 dan F1-Score 0.88, yang mengindikasikan bahwa model mampu mengidentifikasi kondisi transisi dengan baik. Pada kategori Safe Zone (2), hasilnya bahkan lebih optimal, dengan presisi 0.93, recall 0.95, dan F1-Score 0.94, menunjukkan bahwa Random Forest sangat efektif dalam mengenali perusahaan yang berada pada kondisi aman. Dengan demikian, model ini lebih andal dalam memprediksi kondisi stabil dan moderat, namun masih kurang sensitif dalam mendeteksi potensi kebangkrutan.

Model SVM menunjukkan performa yang cukup seimbang, namun efektivitasnya berbeda pada setiap kategori risiko. Untuk kategori Potentially Bankrupt (0), nilai presisi (0.57) dan recall (0.55) yang relatif rendah menghasilkan F1-Score sebesar 0.56, menunjukkan bahwa model masih belum optimal dalam mengenali perusahaan dengan kondisi risiko tertinggi. Pada kategori Grey Area (1), performa model meningkat dengan presisi sebesar 0.85 dan recall 0.82, menghasilkan F1-Score 0.84, yang menunjukkan kemampuan SVM dalam mengidentifikasi perusahaan yang berada dalam kondisi menengah secara cukup konsisten. Sementara itu, pada kategori Safe Zone (2), SVM memiliki presisi 0.79 dan recall 0.85 dengan F1-Score 0.81, menandakan bahwa model mampu mengklasifikasikan perusahaan dengan kondisi sehat secara relatif baik, meskipun hasilnya tidak sekuat Random Forest. Dengan demikian, SVM tergolong stabil dalam memprediksi kondisi normal dan menengah, namun masih terbatas dalam mendeteksi perusahaan yang berada pada potensi kebangkrutan.

Model	Class	Precision	Recall	F1-Score
MLR	0	0.73	0.88	0.80
	1	0.55	0.14	0.22
	2	0.81	0.91	0.86
Artificial Neural Network	0	0.55	0.57	0.56
	1	0.89	0.89	0.89
	2	0.84	0.82	0.83
Random Forest	0	0.75	0.41	0.53
	1	0.82	0.95	0.88
	2	0.93	0.95	0.94
SVM	0	0.57	0.55	0.56
	1	0.85	0.82	0.84
	2	0.79	0.85	0.81

C. Akurasi dan performa setiap model

Hasil menunjukkan bahwa Random Forest memberikan akurasi tertinggi (0.85) dibandingkan metode lainnya. Hal ini mengindikasikan bahwa Random Forest memiliki kemampuan yang baik dalam mempelajari variasi data dan menghasilkan keputusan klasifikasi yang stabil melalui mekanisme ensemble learning. Meskipun demikian, nilai F1-Score (0.78) sedikit lebih rendah daripada akurasinya, yang menunjukkan adanya ketidakseimbangan performa antar kelas prediksi.

Artificial Neural Network menunjukkan performa yang relatif stabil dan konsisten, dimana nilai Akurasi dan F1-Score keduanya mencapai 0.82. Hal ini mencerminkan bahwa Artificial Neural Network mampu menangkap pola non-linear antar variabel secara lebih optimal dan memberikan hasil klasifikasi yang proporsional pada setiap kelas.

Pada model SVM, nilai akurasi (0.78) dan F1-Score (0.74) menunjukkan performa yang berada di tingkat menengah. SVM cenderung bekerja optimal pada data yang memiliki margin pemisahan jelas, sehingga ketika struktur data bersifat kompleks atau berlapis, performanya tidak sebaik model ensemble dan jaringan saraf.

Sementara itu, MLR menghasilkan akurasi 0.7617 dan F1-Score 0.7207, yang relatif lebih rendah dibandingkan model berbasis machine learning lainnya. Namun demikian, nilai kontribusi MLR dalam penelitian ini bukan pada akurasi prediksi yang tertinggi, melainkan pada kemampuannya memberikan interpretasi parameter model secara langsung. Melalui koefisien regresi dan nilai odds ratio, MLR mampu menjelaskan pengaruh dan arah kontribusi

setiap variabel prediktor terhadap kategori kesehatan perusahaan, sehingga memiliki signifikansi penting dalam konteks penjelasan fenomena dan pengambilan keputusan manajerial.

Secara ksesluruhan, akurasi model menunjukkan variasi peningkatan dibandingkan dengan baseline. Decision Tree dan Random Forest meningkat menjadi 78,81% dan 83,90%. SVM menunjukkan peningkatan signifikan dari baseline dari 37% menjadi 78,81%. Hal ini menunjukkan bahwa algoritma ini sangat sensitif terhadap pemilihan parameter. K-NN juga mengalami peningkatan dari 69% menjadi 72,88%, sementara Naive Bayes mengalami sedikit penurunan dari 69% menjadi 67,80%. XGBoost, yang pada baseline sudah cukup optimal, juga mengalami sedikit penurunan sedikit dari 83% menjadi 82,20% setelah tuning.

D. Interpretasi Model Regresi Multinomial Logistik

Model Regresi Logistik Multinomial (MLR) menawarkan tingkat interpretabilitas yang lebih tinggi dibandingkan model lainnya. Melalui koefisien regresi dan nilai odds ratio, MLR mampu mengidentifikasi arah serta besaran pengaruh masing-masing variabel keuangan terhadap kemungkinan suatu perusahaan berada pada kategori risiko tertentu. Dengan demikian, MLR menjadi relevan dalam konteks analisis kebijakan dan penilaian risiko, karena tidak hanya menghasilkan prediksi, tetapi juga memberikan penjelasan mengenai faktor-faktor yang mendorong peningkatan atau penurunan tingkat risiko. Meskipun performa akurasi MLR relatif lebih rendah dibandingkan model berbasis pembelajaran mesin, model ini tetap unggul dalam menjawab pertanyaan terkait alasan dan mekanisme terbentuknya kategori risiko pada perusahaan.

E. Interpretasi Model Artificial Neural Network

Dalam penelitian ini, Artificial Neural Network menunjukkan kinerja prediksi tertinggi dibandingkan model lain dengan F1-Score sebesar 0,82. Nilai ini menunjukkan kemampuan Artificial Neural Network dalam mempertahankan keseimbangan antara precision dan recall, sehingga prediksi untuk masing-masing kelas lebih stabil dan konsisten. Artificial Neural Network dilatih selama 100 epoch, dan pemantauan terhadap Training dan Validation Loss serta Accuracy memberikan gambaran proses pembelajaran model.

Artificial Neural Network (ANN) yang dibangun pada penelitian ini menggunakan arsitektur multi-layer perceptron dengan beberapa lapisan dense, batch normalization, dan dropout. Struktur model terdiri dari lapisan input, beberapa hidden layer dengan jumlah neuron bervariasi (128, 96, 96, 224), serta lapisan output 3 neuron yang sesuai dengan klasifikasi tiga kategori target. Batch normalization diterapkan untuk menstabilkan distribusi input ke setiap lapisan dan mempercepat konvergensi, sementara dropout digunakan untuk mencegah over fitting pada model.



Hasil pelatihan menunjukkan bahwa Training Accuracy terus meningkat hingga lebih dari 90%, sedangkan Validation Accuracy cepat naik di awal namun stagnan di level sekitar 75%-80%. Fenomena ini mengindikasikan bahwa model terlalu fokus menghafal detail data pelatihan dan gagal meningkatkan performa pada data yang belum pernah dilihat. Dengan kata lain, terdapat Bias-Variance Tradeoff yang tidak optimal, di mana peningkatan performa pada data pelatihan setelah epoch ke-20 tidak lagi berkontribusi pada akurasi validasi.

Loss function menunjukkan penurunan konsisten pada data training, sementara val_loss relatif stabil pada level tertentu, mendukung indikasi over fitting ringan. Secara keseluruhan, Artificial Neural Network terbukti mampu menangkap pola non-linear dan interaksi kompleks antarvariabel yang sulit diidentifikasi oleh model linier.

Namun, sifat Artificial Neural Network yang bersifat black-box membatasi kemampuan untuk menjelaskan kontribusi masing-masing variabel terhadap output.

F. Hasil Pemodelan Machine Learning

Hasil terbaik didapatkan pada rasio pembagian data 80:20. Hasil menunjukkan kombinasi parameter terbaik untuk masing-masing algoritma seperti, Decision Tree memiliki $n_estimators = 240$ dan $max_depth = 21$, Random Forest memiliki $n_estimators = 240$ dan $max_depth = 21$, dan XGBoost memiliki $n_estimators = 205$, $max_depth = 12$ dan $learning_rate = 0.148$. Setelah model dilatih ulang dengan parameter yang paling cocok, kinerjanya dievaluasi kembali pada data uji.

Perbandingan performa dilakukan pada lima skenario rasio data latih-uji (90/10, 80/20, dan 70/30). Setiap model diuji dalam dua kondisi, yaitu baseline dan setelah hyperparameter tuning. Analisis dilakukan berdasarkan stabilitas per kategori risiko (0, 1, dan 2) menggunakan F1-Score yang merupakan ukuran yang mampu menyeimbangkan false positive dan false negative pada setiap kelas, sehingga lebih relevan dalam konteks penilaian risiko kebangkrutan yang memiliki tingkat ketidakseimbangan kategori.

Secara keseluruhan, penyesuaian hyperparameter terutama menguntungkan algoritma yang sangat bergantung pada parameter, dengan peningkatan terbesar terlihat pada SVM. Akurasi tertinggi setelah tuning terdapat pada Random Forest.

Model		Sebelum Tuning				Setelah Tuning			
Category	Ratio	Akura si	F1 (0)	F1 (1)	F1 (2)	Akurasi	F1 (0)	F1 (1)	F1 (2)
Decision Tree	90:10	0.83	0.88	0.57	0.89	0.94	0.86	0.76	0.84
Random Forest	90:10	0.81	0.97	0.67	0.92	1.00	0.92	0.88	0.93
SVM	90:10	0.31	0.52	0.35	0.00	1.00	0.88	0.86	0.86
KNN	90:10	0.66	0.90	0.84	0.85	1.00	0.88	0.86	0.86
Naive Bayes	90:10	0.46	0.76	0.44	0.50	0.54	0.42	0.66	0.48
XGBoost	90:10	0.92	0.91	0.71	0.94	1.00	0.92	0.87	0.91
Decision Tree	80:20	0.77	0.79	0.56	0.85	0.79	0.85	0.78	0.85
Random Forest	80:20	0.86	0.95	0.53	0.90	0.86	0.92	0.88	0.93
SVM	80:20	0.37	0.71	0.34	0.00	0.80	0.89	0.86	0.85
KNN	80:20	0.70	0.72	0.51	0.79	0.73	0.91	0.87	0.86
Naive Bayes	80:20	0.69	0.71	0.27	0.82	0.68	0.51	0.36	0.66
XGBoost	80:20	0.82	0.86	0.56	0.88	0.81	0.92	0.89	0.92
Decision Tree	70:30	0.78	0.82	0.44	0.88	0.79	0.85	0.79	0.85
Random Forest	70:30	0.82	0.87	0.46	0.89	0.83	0.93	0.88	0.93
SVM	70:30	0.82	0.55	0.23	0.05	0.76	0.89	0.88	0.85
KNN	70:30	0.67	0.75	0.43	0.75	0.76	0.90	0.87	0.86
Naive Bayes	70:30	0.55	0.57	0.42	0.65	0.67	0.36	0.52	0.61

XGBoost	70:30	0.83	0.88	0.53	0.89	0.88	0.93	0.88	0.92
---------	-------	------	------	------	------	------	------	------	------


Hasil perbandingan kinerja model sebelum dan setelah dilakukan hyperparameter tuning menunjukkan bahwa proses tuning memberikan peningkatan stabilitas prediksi di hampir semua model, terutama pada kategori 0 (Bankrupt) dan 2 (Sehat). Pada kondisi baseline, beberapa model seperti Decision Tree dan Random Forest sudah menunjukkan performa yang cukup baik pada kategori 0 dan 2, namun masih kurang konsisten pada kategori 1 (Abu/Grey Area). Setelah dilakukan tuning, model secara umum mengalami peningkatan nilai F1-score, ditandai dengan naiknya kemampuan model dalam membedakan kategori secara lebih seimbang. Random Forest dan XGBoost menjadi model yang paling konsisten menunjukkan peningkatan performa pada seluruh rasio pembagian data, dengan F1-score yang lebih tinggi pada kategori 1 dan mendekati stabil pada kategori lainnya. Sebaliknya, SVM dan Naive Bayes menunjukkan keterbatasan dalam mengklasifikasikan kategori abu sejak baseline, dan peningkatan setelah tuning tidak terlalu signifikan, yang mengindikasikan bahwa kedua model tersebut kurang mampu menangkap pola kompleks pada data penelitian ini.

Secara keseluruhan, tuning terbukti meningkatkan kemampuan generalisasi model terutama pada data uji. Peningkatan performa yang paling signifikan setelah tuning terlihat pada model SVM. Pada kondisi baseline, SVM menunjukkan kinerja yang rendah dan tidak stabil antar kategori, namun setelah tuning performanya meningkat secara konsisten pada tiga kelas. Random Forest dan KNN juga mengalami peningkatan yang jelas, meskipun tidak sebesar SVM. Sementara itu, XGBoost tetap stabil dengan performa tinggi sejak baseline, sehingga peningkatannya tidak terlalu mencolok. Sebaliknya, Decision Tree hanya meningkat moderat dan Naive Bayes cenderung tidak stabil setelah tuning. Dengan demikian, tuning paling berdampak pada model yang sensitif terhadap penentuan parameter, khususnya SVM.

G. Perbandingan Tiga Model

1. Perbandingan Confusion Matrix

Prediksi status risiko kebangkrutan perusahaan dilakukan menggunakan empat model klasifikasi menghasilkan kinerja tiap model yang dievaluasi menggunakan confusion matrix untuk tiga kategori yaitu Potentially Bankrupt (0), Grey Area (1), dan Safe Zone (2). Hasil prediksi disajikan pada Gambar berikut.



Dalam kategori Potentially Bankrupt, MLR menunjukkan jumlah prediksi tertinggi dibanding model lainnya, menandakan kemampuan deteksi perusahaan berisiko tinggi yang paling sensitif. Artificial Neural Network

mampu menangkap sebagian besar perusahaan berisiko tinggi, meskipun terdapat beberapa kesalahan prediksi ke Grey Area dan Safe Zone. SVM memiliki prediksi tepat moderat, sedangkan Random Forest menunjukkan jumlah prediksi tepat paling rendah dan menghasilkan false negative terbanyak, sehingga beberapa perusahaan berisiko tinggi tidak terdeteksi.

Pada kategori Grey Area, Random Forest dan Artificial Neural Network menunjukkan akurasi tertinggi, mampu menangkap sebagian besar perusahaan yang berada di zona menengah. Sebaliknya, MLR memiliki jumlah prediksi salah paling banyak untuk kategori ini, yang menunjukkan keterbatasan model linear dalam menangkap pola non-linear pada kelas menengah. SVM berada di antara Artificial Neural Network dan MLR, dengan sejumlah kesalahan prediksi yang terjadi ke kategori Potentially Bankrupt dan Safe Zone.

Untuk kategori Safe Zone, semua model relatif akurat dalam memprediksi perusahaan aman. Random Forest dan MLR menonjol dengan jumlah prediksi tepat yang tinggi, sedangkan Artificial Neural Network mengalami kesalahan lebih banyak, terutama akibat beberapa perusahaan Safe Zone diprediksi masuk kategori Potentially Bankrupt. SVM menunjukkan akurasi cukup baik, dengan jumlah kesalahan lebih rendah dibanding Artificial Neural Network tetapi sedikit lebih tinggi dibanding Random Forest dan MLR.

Secara keseluruhan, Artificial Neural Network menunjukkan keseimbangan terbaik antara kemampuan mendeteksi Potentially Bankrupt dan akurasi keseluruhan, sedangkan MLR unggul untuk kategori ekstrem (Potentially Bankrupt dan Safe Zone) tetapi kurang efektif untuk Grey Area. Random Forest dan SVM stabil pada kategori dominan, tetapi kurang sensitif terhadap perusahaan berisiko tinggi. Hasil ini menegaskan pentingnya pemilihan model sesuai prioritas analisis: apakah fokus pada deteksi risiko tinggi atau akurasi keseluruhan pada semua kategori.

2. Perbandingan Precision, Recall, dan F1-Score setiap kategori

a. Multinomial Logistic Regression (MLR)

Model MLR menunjukkan performa yang baik pada kelas 0 (Potentially Bankrupt) dan 2 (Safe Zone) dengan F1-Score masing-masing 0.80 dan 0.86, yang menandakan kemampuan model dalam membedakan kondisi keuangan perusahaan yang memiliki variabel-variabel prediktor dengan pola yang berbeda. Namun, performa MLR sangat rendah pada kelas 1 (Grey Area), dengan Recall hanya 0.14, menghasilkan F1-Score sebesar 0.22. Hal ini mengindikasikan bahwa perusahaan yang berada pada kondisi transisi atau tidak stabil sering salah diklasifikasikan ke kelas lain. Kondisi ini dapat terjadi karena ciri keuangan kelas Grey Area lebih ambigu, sehingga model linear seperti MLR tidak cukup fleksibel dalam menangkap variabilitasnya.

b. Artificial Neural Network

Model Artificial Neural Network menunjukkan performa paling stabil dan seimbang di seluruh kelas. Kelas 2 (Safe Zone) menunjukkan nilai Precision, Recall, dan F1-Score yang sangat tinggi (0.89), menandakan bahwa Artificial Neural Network sangat efektif mengenali perusahaan sehat. Pada kelas 0 (Potentially Bankrupt), Artificial Neural Network memberikan F1-Score 0.56, sementara pada kelas 1 (Grey Area) mencapai 0.83, menunjukkan bahwa Artificial Neural Network mampu menangkap pola non-linear yang membedakan kondisi grey area, yang sebelumnya sulit dikenali oleh MLR. Dengan demikian, Artificial Neural Network menjadi model yang paling seimbang dalam mengenali semua kondisi kesehatan perusahaan.

c. Machine Learning

Model Random Forest menunjukkan kinerja klasifikasi yang kuat pada kategori Grey Area (1) dan Safe Zone (2), namun masih terbatas dalam mengidentifikasi kategori Potentially Bankrupt (0). Pada kategori 0, nilai presisi sebesar 0.75 dan recall 0.41 menghasilkan F1-Score 0.53, yang menunjukkan bahwa model cukup tepat dalam memprediksi ketika memilih kategori ini, namun sering gagal mengenali perusahaan yang benar-benar berada pada kondisi berisiko tinggi. Sebaliknya, pada kategori Grey Area (1), performa meningkat signifikan dengan recall 0.95 dan F1-Score 0.88, yang mengindikasikan bahwa model mampu mengidentifikasi kondisi transisi dengan baik. Pada kategori Safe Zone (2), hasilnya bahkan lebih optimal, dengan presisi 0.93, recall 0.95, dan F1-Score 0.94, menunjukkan bahwa Random Forest sangat efektif dalam mengenali perusahaan yang berada pada kondisi aman. Dengan demikian, model ini lebih andal dalam memprediksi kondisi stabil dan moderat, namun masih kurang sensitif dalam mendeteksi potensi kebangkrutan.

Model SVM menunjukkan performa yang cukup seimbang, namun efektivitasnya berbeda pada setiap kategori risiko. Untuk kategori Potentially Bankrupt (0), nilai presisi (0.57) dan recall (0.55) yang relatif rendah menghasilkan F1-Score sebesar 0.56, menunjukkan bahwa model masih belum optimal dalam mengenali

perusahaan dengan kondisi risiko tertinggi. Pada kategori Grey Area (1), performa model meningkat dengan presisi sebesar 0.85 dan recall 0.82, menghasilkan F1-Score 0.84, yang menunjukkan kemampuan SVM dalam mengidentifikasi perusahaan yang berada dalam kondisi menengah secara cukup konsisten. Sementara itu, pada kategori Safe Zone (2), SVM memiliki presisi 0.79 dan recall 0.85 dengan F1-Score 0.81, menandakan bahwa model mampu mengklasifikasikan perusahaan dengan kondisi sehat secara relatif baik, meskipun hasilnya tidak sekuat Random Forest. Dengan demikian, SVM tergolong stabil dalam memprediksi kondisi normal dan menengah, namun masih terbatas dalam mendeteksi perusahaan yang berada pada potensi kebangkrutan.

Output dari analisis data adalah sebagai berikut.

<pre> ===== Multinomial Logit (MNLogit) Evaluation ===== Accuracy : 0.7617021276595745 Precision: 0.6926572951052755 Recall : 0.6454769900302336 F1-Score : 0.625292387227733 Classification Report: precision recall f1-score support 0 0.73 0.88 0.80 78 1 0.55 0.14 0.22 43 2 0.81 0.91 0.86 114 </pre>	<pre> ===== ANN ===== Accuracy : 0.8793103448275862 Precision: 0.8460591133004925 Recall : 0.8190362269309638 F1-Score : 0.8263157894736842 Classification Report: precision recall f1-score support 0 0.75 0.55 0.63 11 1 0.93 0.96 0.95 28 2 0.86 0.95 0.90 19 </pre>
<pre> ===== Random Forest (Tuned) ===== Accuracy : 0.847457627118644 Precision: 0.8310606060606060 Recall : 0.768392426287163 F1-Score : 0.7813898019843936 Classification Report: precision recall f1-score support 0 0.75 0.41 0.53 22 1 0.82 0.95 0.88 57 2 0.93 0.95 0.94 39 </pre>	<pre> ===== SVM (Tuned) ===== Accuracy : 0.7796610169491526 Precision: 0.7372294372294372 Recall : 0.7387232650390545 F1-Score : 0.7374133546614167 Classification Report: precision recall f1-score support 0 0.57 0.55 0.56 22 1 0.85 0.82 0.84 57 2 0.79 0.85 0.81 39 </pre>

Secara ringkas perbandingan adalah sebagaimana tabel berikut.

Model	Class	Precision	Recall	F1-Score
MLR	0	0.73	0.88	0.80
	1	0.55	0.14	0.22
	2	0.81	0.91	0.86
Artificial Neural Network	0	0.55	0.57	0.56
	1	0.89	0.89	0.89
	2	0.84	0.82	0.83
Random Forest	0	0.75	0.41	0.53
	1	0.82	0.95	0.88
	2	0.93	0.95	0.94
SVM	0	0.57	0.55	0.56
	1	0.85	0.82	0.84

	2	0.79	0.85	0.81
--	---	------	------	------

3. Akurasi dan performa setiap model

Hasil menunjukkan bahwa Random Forest memberikan akurasi tertinggi (0.85) dibandingkan metode lainnya. Hal ini mengindikasikan bahwa Random Forest memiliki kemampuan yang baik dalam mempelajari variasi data dan menghasilkan keputusan klasifikasi yang stabil melalui mekanisme ensemble learning. Meskipun demikian, nilai F1-Score (0.78) sedikit lebih rendah daripada akurasinya, yang menunjukkan adanya ketidakseimbangan performa antar kelas prediksi.

Artificial Neural Network menunjukkan performa yang relatif stabil dan konsisten, dimana nilai Akurasi dan F1-Score keduanya mencapai 0.82. Hal ini mencerminkan bahwa Artificial Neural Network mampu menangkap pola non-linear antar variabel secara lebih optimal dan memberikan hasil klasifikasi yang proporsional pada setiap kelas.

Pada model SVM, nilai akurasi (0.78) dan F1-Score (0.74) menunjukkan performa yang berada di tingkat menengah. SVM cenderung bekerja optimal pada data yang memiliki margin pemisahan jelas, sehingga ketika struktur data bersifat kompleks atau berlapis, performanya tidak sebaik model ensemble dan jaringan saraf.

Sementara itu, MLR menghasilkan akurasi 0.7617 dan F1-Score 0.7207, yang relatif lebih rendah dibandingkan model berbasis machine learning lainnya. Namun demikian, nilai kontribusi MLR dalam penelitian ini bukan pada akurasi prediksi yang tertinggi, melainkan pada kemampuannya memberikan interpretasi parameter model secara langsung. Melalui koefisien regresi dan nilai odds ratio, MLR mampu menjelaskan pengaruh dan arah kontribusi setiap variabel prediktor terhadap kategori kesehatan perusahaan, sehingga memiliki signifikansi penting dalam konteks penjelasan fenomena dan pengambilan keputusan manajerial.

	MLR	Artificial Neural Network	Random Forest	SVM
Akurasi	0.76	0.82	0.85	0.78
F1-Score	0.72	0.82	0.78	0.74

Secara ksesluruhan, akurasi model menunjukkan variasi peningkatan dibandingkan dengan baseline. Decision Tree dan Random Forest meningkat menjadi 78,81% dan 83,90%. SVM menunjukkan peningkatan signifikan dari baseline dari 37% menjadi 78,81%. Hal ini menunjukkan bahwa algoritma ini sangat sensitif terhadap pemilihan parameter. K-NN juga mengalami peningkatan dari 69% menjadi 72,88%, sementara Naive Bayes mengalami sedikit penurunan dari 69% menjadi 67,80%. XGBoost, yang pada baseline sudah cukup optimal, juga mengalami sedikit penurunan sedikit dari 83% menjadi 82,20% setelah tuning.

H. Faktor yang mempengaruhi prediksi kebangkrutan berdasarkan Model Regresi Multinomial Logistik

Model Regresi Logistik Multinomial (MLR) menawarkan tingkat interpretabilitas yang lebih tinggi dibandingkan model lainnya. Melalui koefisien regresi dan nilai odds ratio, MLR mampu mengidentifikasi arah serta besaran pengaruh masing-masing variabel keuangan terhadap kemungkinan suatu perusahaan berada pada kategori risiko tertentu. Dengan demikian, MLR menjadi relevan dalam konteks analisis kebijakan dan penilaian risiko, karena tidak hanya menghasilkan prediksi, tetapi juga memberikan penjelasan mengenai faktor-faktor yang mendorong peningkatan atau penurunan tingkat risiko. Meskipun performa akurasi MLR relatif lebih rendah dibandingkan model berbasis pembelajaran mesin, model ini tetap unggul dalam menjawab pertanyaan terkait alasan dan mekanisme terbentuknya kategori risiko pada perusahaan.

Hasil pemodelan yang dilakukan melalui fungsi MNLogit pada Python menyajikan hasil dari standard error, statistik z, dan p-value untuk masing-masing variabel prediktor yang menunjukkan tingkat signifikansi statistik dari pengaruh masing-masing prediktor terhadap variabel dependen. Jika nilai $p < 0,05$, maka pengaruh prediktor tersebut dianggap signifikan pada taraf kepercayaan 5%. Sementara itu, Odds Ratio (e^{β}) digunakan untuk mengubah koefisien logit menjadi bentuk interpretasi peluang, di mana nilai lebih dari 1 menunjukkan

peningkatan peluang kejadian, sedangkan nilai kurang dari 1 menunjukkan penurunan peluang kejadian. Hasil Koefisien Regresi Logistik Multinomial (Log-Odds) ditunjukkan pada Gambar berikut.

1. Interpretasi Model Regresi Multinomial Logistik

Multinomial Logistic Regression Model (MLR), melalui koefisien regresi dan odds ratio, dapat mengidentifikasi arah dan besarnya pengaruh setiap variabel keuangan terhadap kemungkinan perusahaan berada dalam kategori risiko tertentu. Dengan demikian, MLR relevan dalam konteks analisis kebijakan dan penilaian risiko, karena tidak hanya menghasilkan prediksi tetapi juga memberikan penjelasan tentang faktor-faktor yang mendorong kenaikan atau penurunan tingkat risiko.

Hasil pemodelan dari fungsi MNLogit di Python mencakup kesalahan standar, statistik-z, dan nilai-p untuk setiap prediktor, yang menunjukkan signifikansi statistik dari efek setiap prediktor pada variabel dependen, seperti yang dijelaskan dalam Tabel 3. Jika nilai $p < 0,05$, pengaruh prediktor dianggap signifikan pada tingkat kepercayaan 5%. Sementara itu, Rasio Peluang (e^{β}) mengubah koefisien logit menjadi interpretasi probabilitas: nilai yang lebih besar dari 1 menunjukkan peningkatan probabilitas suatu peristiwa, sedangkan nilai kurang dari 1 menunjukkan penurunan probabilitas suatu peristiwa. Hasil Koefisien Regresi Logistik Multinomial (Log-Odds) ditunjukkan pada tabel berikut.

Tabel Multinomial Logistics Regression berikut ini didapatkan dari output program pada gambar berikutnya (setelah tabel).

	Category = 1			Category = 2		
	Coef	Z	Pvalue	Coef	Z	Pvalue
Const	0.42	1.90	0.06	1.18	5.78	0.00
Current Ratio	5.40	4.65	0.00	13.55	11.57	0.00
Cash Ratio	-1.25	-0.83	0.41	-7.58	-5.03	0.00
DAR	-0.70	-5.02	0.00	-1.32	-8.74	0.00
DER	-1.91	-0.66	0.51	-0.56	-0.16	0.87
NPM	0.29	1.41	0.16	0.70	3.23	0.00
ROA	1.74	2.16	0.03	2.32	2.62	0.01
ROE	2.05	0.70	0.48	0.57	0.17	0.87
Majority Ownership	-0.16	-1.25	0.21	-0.18	-1.44	0.15
Independent Commissioner	0.27	1.47	0.14	-0.11	-0.62	0.53
Insider Ownership	-0.07	0.29	0.77	0.22	1.11	0.27
BoC Size	0.17	0.71	0.48	-0.76	-2.81	0.01
BoC Education	-1.41	-2.78	0.01	-0.94	-1.95	0.05
TMT Size	-0.15	-0.67	0.50	1.10	4.38	0.00
TMT Education	1.56	3.08	0.00	1.11	2.30	0.02
Total Assets	-0.45	-3.22	0.00	-1.86	-5.74	0.00
Revenue Growth	0.21	0.79	0.43	0.18	0.64	0.52
Dep. Variable	Category (Z Score)					
Model	MNLogit					
No.Observations	936					
Pseudo R-squared	0.3575					
LLR p-value	4.611e-124					

MNLogit Regression Results						
=====						
Dep. Variable:	Category	No. Observations:	936			
Model:	MNLogit	Df Residuals:	902			
Method:	MLE	Df Model:	32			
Date:	Wed, 29 Oct 2025	Pseudo R-squ.:	0.3575			
Time:	15:59:27	Log-Likelihood:	-617.87			
converged:	False	LL-Null:	-961.61			
Covariance Type:	nonrobust	LLR p-value:	4.611e-124			
=====						
Category=1	coef	std err	z	P> z	[0.025	0.975]

const	0.4162	0.220	1.896	0.058	-0.014	0.846
Current_Ratio	5.3983	1.162	4.646	0.000	3.121	7.676
Cash_Ratio	-1.2540	1.507	-0.832	0.405	-4.208	1.700
DAR	-0.6970	0.139	-5.023	0.000	-0.969	-0.425
DER	-1.9090	2.896	-0.659	0.510	-7.584	3.766
NPM	0.2931	0.208	1.412	0.158	-0.114	0.700
ROA	1.7430	0.808	2.157	0.031	0.159	3.327
ROE	2.0482	2.911	0.704	0.482	-3.657	7.754
Majority_Ownership	-0.1550	0.124	-1.250	0.211	-0.398	0.088
Independent_Commissioner	0.2695	0.184	1.466	0.143	-0.091	0.630
Insider_Ownership	-0.0683	0.235	-0.291	0.771	-0.529	0.392
BoC_Size	0.1725	0.242	0.712	0.477	-0.302	0.648
BoC_Education	-1.4066	0.506	-2.779	0.005	-2.398	-0.415
TMT_Size	-0.1458	0.218	-0.670	0.503	-0.572	0.281
TMT_Education	1.5646	0.508	3.078	0.002	0.568	2.561
Total_Assets	-0.4535	0.141	-3.217	0.001	-0.730	-0.177
Revenue_Growth	0.2136	0.269	0.794	0.427	-0.313	0.741

Category=2	coef	std err	z	P> z	[0.025	0.975]

const	1.1836	0.205	5.775	0.000	0.782	1.585
Current_Ratio	13.5544	1.172	11.565	0.000	11.257	15.851
Cash_Ratio	-7.5824	1.508	-5.028	0.000	-10.538	-4.627
DAR	-1.3175	0.151	-8.742	0.000	-1.613	-1.022
DER	-0.5626	3.552	-0.158	0.874	-7.524	6.399
NPM	0.6970	0.216	3.232	0.001	0.274	1.120
ROA	2.3183	0.885	2.621	0.009	0.585	4.052
ROE	0.5662	3.420	0.166	0.869	-6.137	7.269
Majority_Ownership	-0.1789	0.124	-1.437	0.151	-0.423	0.065
Independent_Commissioner	-0.1147	0.184	-0.622	0.534	-0.476	0.247
Insider_Ownership	0.2213	0.200	1.109	0.267	-0.170	0.612
BoC_Size	-0.7575	0.269	-2.812	0.005	-1.285	-0.230
BoC_Education	-0.9440	0.485	-1.945	0.052	-1.895	0.007
TMT_Size	1.1009	0.251	4.379	0.000	0.608	1.594
TMT_Education	1.1345	0.493	2.300	0.021	0.168	2.101
Total_Assets	-1.8561	0.324	-5.737	0.000	-2.490	-1.222
Revenue_Growth	0.1775	0.279	0.636	0.524	-0.369	0.724
=====						

Output di atas menunjukkan hasil estimasi multinomial logit dengan variabel dependen Kategori (tiga kategori: 0 sebagai kategori referensi, 1 dan 2 sebagai kategori perbandingan). Jumlah pengamatan adalah 936, dan Pseudo R² adalah ±0,36, dengan uji rasio kemungkinan yang sangat signifikan ($p < 0,001$), menunjukkan bahwa model secara keseluruhan menjelaskan variasi dalam kategori dengan cukup baik. Penjelasan untuk setiap variabel adalah sebagai berikut.

2. Faktor-faktor pembeda Kategori 1 vs Kategori, berdasarkan koefisien dan nilai-p dalam blok Kategori = 1.

Beberapa variabel secara signifikan mempengaruhi kemungkinan perusahaan memasuki Kategori 1 daripada Kategori 0, sebagai berikut. Rasio Arus memiliki efek positif dan signifikan (koefisien sekitar 5,40; $p < 0,001$). Ini berarti bahwa semakin tinggi likuiditas jangka pendek perusahaan, semakin besar kemungkinannya dalam Kategori 1 dibandingkan dengan kategori referensi. DAR (Debt to Asset Ratio) memiliki efek negatif dan signifikan (koefisien sekitar -0,70; $p < 0,001$). Peningkatan leverage berbasis aset mengurangi kemungkinan bahwa perusahaan berada dalam Kategori 1 (peluang yang lebih besar tetap ada dalam kategori referensi). ROA

memiliki efek positif dan signifikan (koefisien $\pm 1,74$; $p \approx 0,03$). Semakin tinggi total profitabilitas aset, semakin besar kemungkinan aset akan masuk ke Kategori 1 daripada Kategori 0.

Dewan Komisaris Pendidikan (jenjang pendidikan dewan komisaris) memiliki efek negatif dan signifikan ($p \approx 0,005$). Peningkatan indikator pendidikan BoC sebenarnya mengurangi kemungkinan perusahaan berada dalam Kategori 1; ini menunjukkan bahwa dewan yang lebih terdidik cenderung tetap dalam kategori referensi (misalnya, kategori yang lebih sehat) daripada pindah ke Kategori 1. TMT Education (pendidikan tim manajemen puncak) memiliki efek positif dan signifikan ($p \approx 0,002$), menunjukkan bahwa peningkatan kualitas pendidikan TMT dikaitkan dengan kemungkinan perusahaan berada dalam Kategori 1 dibandingkan dengan kategori referensi. Total Aset memiliki efek negatif dan signifikan ($p \approx 0,037$). Perusahaan yang lebih besar (aset yang lebih tinggi) cenderung tidak berada dalam Kategori 1 dan lebih mungkin berada dalam kategori referensi.

Variabel lain, seperti Rasio Kas, DER, NPM, ROE, struktur kepemilikan, komposisi komisaris independen, kepemilikan orang dalam, ukuran dewan (BoC Size), ukuran TMT, dan Pertumbuhan Pendapatan, tidak signifikan secara statistik pada tingkat 5%, sehingga tidak terbukti membedakan Kategori 1 dari kategori dasar dalam model ini.

3. Faktor pembeda Kategori 2 vs Kategori 0, berdasarkan blok Kategori=2

Untuk Kategori 2 dibandingkan dengan Kategori 0, pola pengaruhnya lebih kuat dan menyebar ke lebih banyak variabel sebagai berikut. Rasio Lancar mengembalikan koefisien positif dan sangat signifikan ($\pm 13,55$; $p < 0,001$). Likuiditas yang lebih tinggi meningkatkan peluang perusahaan untuk berada di Kategori 2 relatif terhadap Kategori 0. Rasio Kas memiliki efek negatif dan signifikan ($p < 0,001$). Semakin besar kas relatif terhadap kewajiban lancar, semakin rendah kemungkinan memasuki Kategori 2; perusahaan dengan rasio kas terhadap kewajiban lancar yang relatif rendah lebih mungkin masuk ke dalam Kategori 2. DAR juga negatif dan signifikan ($p < 0,001$), menunjukkan leverage berbasis aset yang tinggi dan menurunkan peluang berada di Kategori 2; sebaliknya, leverage yang lebih rendah dikaitkan dengan Kategori 2 dalam model ini (interpretasi ekonominya dapat dikaitkan dengan perbedaan struktur pendanaan dan profil risiko). NPM (Net Profit Margin) memiliki efek positif dan signifikan ($p \approx 0,001$); ROA dan ROE juga positif dan signifikan ($p < 0,01$). Ketiga indikator profitabilitas ini menunjukkan bahwa perubahan kualitas laba terkait erat dengan perbedaan probabilitas perusahaan berada dalam Kategori 2 dibandingkan dengan kategori dasar.

Dari sisi tata kelola, BoC Education memiliki efek (adverse) yang signifikan, sedangkan TMT Size dan TMT Education memiliki efek positif dan signifikan. Hal ini menunjukkan bahwa konfigurasi dan kualitas manajemen puncak, serta pendidikan dewan, berperan dalam membedakan perusahaan Kategori 2 dari kategori referensi. Total Aset bersifat negatif dan signifikan, menunjukkan bahwa perusahaan dengan aset yang lebih besar cenderung tidak masuk dalam Kategori 2; Dengan kata lain, perusahaan yang lebih kecil lebih mungkin termasuk dalam kategori ini.

Variabel lain, seperti DER, Kepemilikan Mayoritas, Komisaris Independen, Kepemilikan Orang Dalam, Ukuran BoC, dan Pertumbuhan Pendapatan, tidak signifikan pada tingkat 5% (ada yang mendekati ambang batas 0,05), sehingga peran mereka dalam membedakan Kategori 2 dari Kategori 0 tidak dapat ditetapkan secara statistik.

4. Diskusi

Secara umum, hasil estimasi logit MNL dalam penelitian ini menegaskan bahwa rasio likuiditas, leverage, profitabilitas, ukuran perusahaan, dan karakteristik dewan dan manajemen puncak merupakan faktor utama yang membedakan perusahaan di masing-masing kategori (Kategori 0, 1, dan 2). Pola ini konsisten dengan berbagai studi empiris yang meneliti penentu kesulitan keuangan di Indonesia dan negara berkembang lainnya, yang umumnya menemukan bahwa kombinasi likuiditas, leverage, profitabilitas, dan ukuran perusahaan merupakan prediktor utama kondisi kesehatan/tidak sehat perusahaan [20]; [21]; [22]

a. Likuiditas, leverage, dan risiko kesulitan keuangan

Temuan bahwa Rasio Saat Ini memiliki efek positif dan signifikan pada probabilitas perusahaan berpindah dari Kategori 0 ke Kategori 1 dan Kategori 2 memperkuat pandangan bahwa likuiditas adalah garis pertahanan pertama terhadap kesulitan. Perusahaan dengan modal kerja yang memadai relatif lebih mampu memenuhi kewajiban jangka pendek dan menyerap guncangan arus kas, sehingga profil risikonya berbeda dengan perusahaan dengan likuiditas yang ketat. Ini sejalan dengan Utami et al. [20] yang menunjukkan bahwa rasio keuangan, terutama likuiditas dan profitabilitas, berperan penting dalam memprediksi kesulitan keuangan di Indonesia, serta dengan bukti Runis et al. (2021) dan Azalia (2019), yang menegaskan bahwa rasio likuiditas berkontribusi signifikan terhadap model prediksi marabahaya di perusahaan manufaktur.

Di sisi lain, hasil bahwa Rasio Kas memiliki koefisien negatif dan signifikan dalam Kategori 2 menunjukkan bahwa memegang terlalu banyak uang tunai tidak selalu menunjukkan kondisi yang paling sehat. Dalam konteks ini, perusahaan dalam Kategori 2 tampaknya menggunakan uang tunai lebih agresif untuk ekspansi atau investasi, sehingga tingkat kas relatif terhadap kewajiban lancar sebenarnya lebih rendah. Pola ini sejalan dengan temuan Masdupi, Tasman, dan Davista (2018), yang menunjukkan bahwa likuiditas, leverage, dan profitabilitas harus dibaca bersama, karena perusahaan yang terlalu konservatif dalam memegang uang tunai mungkin mengorbankan peluang pertumbuhan.

Untuk leverage (DAR/DER), hasilnya menunjukkan pola yang tidak signifikan secara konsisten di semua kategori, tetapi ketika signifikan, koefisiennya cenderung negatif. Ini berarti bahwa peningkatan leverage yang tak terelakkan sebenarnya menurunkan kemungkinan bahwa perusahaan berada dalam kategori berkinerja lebih baik, yang konsisten dengan teori trade-off: utang di atas tingkat optimal meningkatkan biaya kesulitan. Utami dkk. [20] menemukan bahwa leverage dapat mengurangi kemungkinan kesukasan ketika perusahaan tetap berada di zona non-marabahaya, sedangkan Runis et al. [21] dan Azalia [22] menunjukkan bahwa leverage yang terlalu tinggi meningkatkan risiko kesulitan di kalangan perusahaan manufaktur Indonesia.

b. Profitabilitas, ukuran perusahaan, dan pertumbuhan

Signifikansi NPM, ROA, dan ROE (terutama untuk Kategori 2) menegaskan bahwa profitabilitas tetap menjadi sinyal kesehatan keuangan terkuat. Utami dkk. [20] menemukan bahwa profitabilitas adalah prediktor tekanan keuangan yang paling stabil. Sebaliknya, Runis et al. [21] menunjukkan bahwa profitabilitas yang tinggi dikaitkan dengan kemungkinan kondisi tertekan yang lebih rendah. Studi lain, seperti Anggrainy [23] juga mendukung gagasan bahwa profitabilitas yang lebih tinggi dikaitkan dengan pengurangan risiko kesulitan dan peningkatan nilai perusahaan.

Dalam model tersebut, Kategori 2, yang terkait dengan nilai NPM, ROA, dan ROE yang lebih baik, dapat ditafsirkan sebagai kelompok dengan kinerja keuangan yang relatif lebih kuat daripada kategori referensi, konsisten dengan literatur, yang memandang profitabilitas sebagai indikator inti kesehatan perusahaan.

Temuan bahwa Total Aset (ukuran perusahaan) memiliki koefisien negatif dan signifikan menunjukkan bahwa perusahaan besar cenderung tetap dalam kategori referensi. Sebaliknya, perusahaan yang lebih kecil relatif mudah dimasukkan ke dalam Kategori 1 atau 2. Runis et al. [21] menemukan bahwa ukuran perusahaan dapat mengurangi kemungkinan kesulitan karena perusahaan besar memiliki akses yang lebih luas ke pendanaan dan diversifikasi yang lebih baik. Namun, penelitian lain, seperti Rachman [24] mencatat bahwa efek ukuran tidak selalu linier; Di sektor-sektor tertentu, ukuran perusahaan dapat gagal memoderasi pengaruh rasio keuangan jika kualitas aset dan tata kelola lemah. Hasil Mother berada di antara dua pandangan ini: ukuran perusahaan penting, tetapi itu tidak cukup tanpa dukungan profitabilitas dan tata kelola yang baik.

c. Tata kelola: pendidikan dewan, kapasitas TMT, dan mekanisme lainnya

Dari segi tata kelola, hasil yang paling menarik adalah signifikansi BoC Education dan TMT Education/TMT Size. Koefisien negatif untuk BoC Education menunjukkan bahwa dewan komisaris dengan tingkat pendidikan yang lebih tinggi cenderung menjaga perusahaan dalam kategori referensi (lebih stabil) daripada dalam Kategori 1 atau 2. Hal ini sejalan dengan temuan Darmadi [25] yang menunjukkan bahwa kualifikasi pendidikan anggota dewan dan CEO, seperti gelar pascasarjana dan latar belakang keuangan, berkorelasi positif dengan kinerja perusahaan (ROA, Tobin's Q) di Indonesia. Madyan dkk. [26] juga membuktikan bahwa tingkat pendidikan formal direksi bank publik memiliki pengaruh positif yang signifikan terhadap profitabilitas (ROA dan NIM). Temuan terbaru Sriwiti [27] bahkan menegaskan bahwa pengalaman, edukasi, dan kompensasi direksi bersama-sama terkait dengan kinerja keuangan bank, menegaskan pentingnya sumber daya manusia dalam tata kelola. Sebaliknya, koefisien positif dan signifikan untuk TMT Education dan TMT Size menunjukkan bahwa tim manajemen puncak yang lebih besar dan lebih terdidik cenderung mendorong perusahaan ke Kategori 1 atau 2. Ini sejalan dengan teori eselon atas, yang menyatakan bahwa karakteristik manajer puncak memengaruhi selera risiko, strategi pertumbuhan, dan keputusan keuangan.

Di sisi lain, kepemilikan mayoritas, kepemilikan orang dalam, dan proporsi komisaris independen tidak tampak signifikan secara konsisten dalam model tersebut. Hal ini sejalan dengan literatur tata kelola di Indonesia, yang sering menemukan bukti beragam tentang efektivitas mekanisme tersebut bila digunakan sendiri. Beberapa penelitian telah menunjukkan bahwa komisaris independen hanya efektif jika disertai dengan Komite Audit yang aktif, transparansi tinggi, dan sistem insentif yang tepat, so that their contribution to the prevention of distress is not always captured by their proportion on the board. These results suggest that the quality and individual capacity of the board/TMT (e.g., education and experience) are more visible in the data than the formal ownership structure and the board's composition.

5. Kesimpulan

Studi ini menganalisis pengaruh beberapa rasio keuangan utama, seperti profitabilitas, leverage, likuiditas, pertumbuhan, dan indikator modal, dan karakteristik tata kelola perusahaan asuransi (ukuran dan komposisi dewan, kehadiran dan intensitas komite audit, dan pola kepemilikan) terhadap probabilitas perusahaan berada dalam kondisi sehat, area abu-abu, atau kesulitan. Dengan menggunakan pendekatan multinomial logistic regression (MNLogit), model mencapai akurasi klasifikasi 76,17%, dengan presisi rata-rata 0,69, recall 0,65, dan skor F1 0,63. Secara khusus, MNLogit cukup baik dalam membedakan antara perusahaan sehat dan tertekan (F1-Score sekitar 0,80-0,86), meskipun masih belum tepat dalam mengidentifikasi perusahaan di area abu-abu (F1-Score 0,22).

Hasil penelitian ini menunjukkan bahwa kombinasi rasio keuangan dan variabel tata kelola yang digunakan cukup informatif untuk memetakan profil risiko perusahaan asuransi, sekaligus menegaskan bahwa transisi ke kondisi rentan (grey area) cenderung lebih lancar dan lebih kompleks daripada perbedaan antara perusahaan yang benar-benar sehat dan perusahaan yang tertekan. Secara teoritis, temuan ini memperkuat argumen bahwa model multinomial lebih tepat untuk pengawasan berbasis risiko karena dapat mewakili spektrum berjenjang dari kondisi perusahaan, daripada dikotomi sehat-tidak sehat seperti dalam model biner tradisional.

Dalam praktiknya, hasil penelitian ini dapat digunakan oleh regulator untuk meningkatkan sistem peringatan dini dengan mengidentifikasi indikator peringatan dini dan memicu rasio keuangan yang terkait dengan probabilitas perusahaan berada dalam kategori grey area dan kesulitan. Model ini menghasilkan probabilitas dapat diintegrasikan ke dalam pengawasan di luar lokasi dan di tempat yang lebih ditargetkan, misalnya, untuk menyusun daftar pantauan perusahaan berisiko dan untuk merancang intervensi bertahap sebelum gagal bayar terjadi. Untuk manajemen asuransi, variabel keuangan dan tata kelola yang terbukti signifikan dapat dijadikan fokus pemantauan dalam sistem peringatan dini internal, sehingga kebijakan mitigasi, seperti pengetatan penjaminan emisi, penyesuaian strategi investasi dan reasuransi, serta penguatan praktik tata kelola, dapat diaktifkan sejak dini ketika indikator kunci mulai bergeser ke zona rentan.

Penelitian ini masih memiliki keterbatasan, antara lain cakupan data yang terbatas untuk periode dan kelompok perusahaan tertentu, serta dominasi indikator keuangan, yang belum sepenuhnya menangkap pengaruh faktor non-keuangan lainnya, seperti kualitas manajemen risiko dan kondisi ekonomi makro. Ke depannya, penelitian dapat diperluas dengan memperluas sampel, menambahkan variabel non-keuangan yang lebih kaya (misalnya, indikator manajemen risiko dan kualitas tata kelola yang lebih rinci), dan membandingkan MNLogit dengan pendekatan pembelajaran mesin multi-kelas untuk meningkatkan deteksi area abu-abu tanpa mengorbankan kemudahan interpretasi bagi regulator dan praktisi.

CAPAIAN LUARAN

Capaian Luaran dan status luaran dengan membandingkan target sesuai proposal dengan realisasi yang sudah dilaksanakan dituliskan pada tabel di bagian D.

D. STATUS LUARAN: Tuliskan jenis, identitas dan status ketercapaian setiap luaran wajib dan luaran tambahan (jika ada) yang dijanjikan. Jenis luaran dapat berupa publikasi, perolehan kekayaan intelektual, atau luaran lainnya yang telah dijanjikan pada proposal. Uraian status luaran harus didukung dengan bukti kemajuan ketercapaian luaran sesuai dengan luaran yang dijanjikan. Lengkapi isian jenis luaran yang dijanjikan serta mengunggah bukti dokumen ketercapaian luaran melalui BIMA.

TARGET		
Luaran Wajib: Publikasi 1 Artikel	Jurnal Bereputasi Q4	Nama Jurnal Asian Academy of Management Journal of Accounting and Finance (AAMJAF) ISSN: 1823-4992 eISSN: 2180-4192.
Luaran Tambahan 1: Konferensi Internasional 1 Artikel		Nama Konferensi International Conference on Accounting and Finance ICAF 2026
Luaran Tambahan 2 Buku ber ISBN		UPP STIMYKPN
REALISASI		
3 ARTIKEL		
JUDUL ARTIKEL: Bibliometric Analysis of Bankruptcy Prediction in Financial Institutions: Themes, Evidence, and a Future Research Agenda	PUBLIKASI PADA: Capital Markets Review Terindeks pada: • ABDC Journal Quality List • Research Papers in Economics (RePEc), • MyJournal • MyCite by Citation and Infometrics Centre (formerly known as Malaysia Citation Centre (MCC)) • Google Scholar.	TAHAPAN: Under review
JUDUL ARTIKEL: Does Machine Learning Predict Bankruptcy Better than Neural Networks? Empirical Evidence from Indonesia's Insurance Company	PUBLIKASI PADA: Quality – Access to Success Jurnal Bereputasi Q4	TAHAPAN: Under review
JUDUL ARTIKEL: Factors Influencing Bankruptcy Prediction in Indonesia's Insurance Company: a Multinomial Logistic Regression Approach	PUBLIKASI PADA: Journal of Industrial and Management Optimization (JIMO) Jurnal Internasional Bereputasi Q3	TAHAPAN: Under review
2 KONFERENSI INTERNASIONAL		
JUDUL PRESENTASI: Is Machine Learning Predicting Bankruptcy Better than Neural Networks and Logistic Regression? Empirical Evidence from Indonesia's Insurance Company	KONFERENSI PADA: International Conference on Business, Economics and Management (BEM - 25)	PELAKSANAAN: Terlaksana pada tanggal 11 Desember 2025
JUDUL PRESENTASI: Insurance Company Bankruptcy Prediction: A Comparison of Machine Learning, Neural Network and Logistic Regression Approaches	KONFERENSI PADA: IIARP-Glovento Conference November 2025	PELAKSANAAN: Terlaksana pada tanggal 16 November 2025

BUKU		
JUDUL BUKU Prediksi Kebangkrutan Perusahaan Asuransi: Pendekatan Machine Learning, Neural Network, dan Regresi Logistik (Konsep dan Implementasi)	PENERBIT: UPP STIM YKPN	TAHAPAN Selesai Seting Buku dan proses menunggu ISBN dan cetak buku

E. **PERAN MITRA:** Tuliskan realisasi kerjasama dan kontribusi Mitra baik *in-kind* maupun *in-cash* serta mengunggah bukti dokumen pendukung sesuai dengan kondisi yang sebenarnya. Bukti dokumen realisasi kerjasama dengan Mitra dapat diunggah melalui BIMA.

Catatan:

Bagian ini wajib diisi untuk penelitian terapan, untuk penelitian dasar (Fundamental, Pascasarjana, PKDN, Dosen Pemula) boleh mengisi bagian ini (tidak wajib) jika melibatkan mitra dalam pelaksanaan penelitiannya

Tidak ada kerjasama dengan mitra dalam proses penelitian ini.

F. **KENDALA PELAKSANAAN PENELITIAN:** Tuliskan kesulitan atau hambatan yang dihadapi selama melakukan penelitian dan mencapai luaran yang dijanjikan, termasuk penjelasan jika pelaksanaan penelitian dan luaran penelitian tidak sesuai dengan yang direncanakan atau dijanjikan.


Tidak ada kendala yang berarti pada proses melakukan penelitian mulai dari pencarian data sampai dengan olah data dan analisis data sampai dengan penulisan artikel. Olah data dan analisis hasil penelitian sudah sesuai dengan yang dijanjikan pada proposal. Kendala terjadi pada publikasi artikel.

Untuk mengantisipasi perlunya waktu untuk pencarian data, peneliti menyusun artikel Bibliometric dan dikirimkan ke Jurnal Asian Academy of Management Journal of Accounting and Finance (AAMJAF) ISSN: 1823-4992 eISSN: 2180-4192 sebagaimana dijanjikan pada proposal, tetapi ditolak karena tidak menerima bibliometric. Penelitian ini bisa menghasilkan 3 artikel ilmiah yang sudah dikirimkan ke jurnal sebagaimana dituliskan pada tabel status luaran, namun semuanya masih dalam proses review, belum accepted apalagi publish.

G. **RENCANA TAHAPAN SELANJUTNYA:** Tuliskan dan uraikan rencana penelitian selanjutnya berdasarkan indikator luaran yang telah dicapai, rencana realisasi luaran wajib yang dijanjikan dan tambahan (jika ada) di tahun berikutnya serta *roadmap* penelitian keseluruhan. Pada bagian ini diperbolehkan untuk melengkapi penjelasan dari setiap tahapan dalam metoda yang akan direncanakan termasuk jadwal berkaitan dengan strategi untuk mencapai luaran seperti yang telah dijanjikan dalam proposal. Jika diperlukan, penjelasan dapat juga dilengkapi dengan gambar, tabel, diagram, serta pustaka yang relevan. Jika laporan kemajuan merupakan laporan pelaksanaan tahun terakhir, pada bagian ini dapat dituliskan rencana penyelesaian target yang belum tercapai.

Rencana penelitian selanjutnya adalah sebagaimana gambar berikut, pada bagian USULAN TAHUN KEDUA. Topik yang direncanakan adalah Determinasi Intention to Buy Insurance di Indonesia: Pengujian Extended Theory of Planned Behavior melalui Trust, Perceived Risk, Perceived Usefulness, dan Insurance Literacy menggunakan PLS-SEM yang akan diuji menggunakan SmartPLS 4.


Outcome berupa luaran wajib dan luaran tambahan adalah sebagaimana gambar di ujung kanan.



Rincian kegiatan tahun II yang merupakan lanjutan tahun I adalah sebagaimana gambar berikut.

Observasi data Perusahaan asuransi bermasalah dan Pencarian data keuangan dan non keuangan (<i>annual report</i>) untuk analisis prediksi kebangkrutan		Penyusunan Laporan tahun I dan Persiapan penelitian tahun II		1. Analisis lanjutan tahun I dengan tambahan data 2. Analisis data primer bersumber kuesioner dan wawancara		Penyusunan Laporan tahun II	
MULAI KEGIATAN		TAHUN I		TAHUN II			
Tabulasi Data		Olah data 1. Regresi Logistik 2. Neural Network Machine Learning		- Tabulasi Data Sekunder dan Data Primer - Tabulasi hasil wawancara		Olah Data 1. SEM PLS 2. Regresi Logistik 3. Neural Network 4. Machine Learning	
HASIL PENELITIAN: Penetapan model Prediksi Kebangkrutan pada Perusahaan Asuransi				HASIL PENELITIAN: Penetapan Model Intention to buy insurance dan prediksi peminatan asuransi			
Luaran: 1. Satu artikel di Jurnal Internasional Bereputasi 2. Satu artikel di proceeding International Conference 3. Satu Buku ber ISBN				Luaran: 1. Satu artikel di Jurnal Internasional Bereputasi 2. Satu artikel di proceeding International Conference 3. Satu Buku ber ISBN			

Model Penelitian dengan topik Determinasi Intention to Buy Insurance di Indonesia: Pengujian Extended Theory of Planned Behavior melalui Trust, Perceived Risk, Perceived Usefulness, dan Insurance Literacy menggunakan PLS-SEM yang akan diuji menggunakan SmartPLS 4 adalah sebagaimana gambar berikut.



Penelitian ini memposisikan intention to buy insurance sebagai outcome utama dan mengembangkan model Extended TPB yang menggabungkan trust, perceived risk, perceived usefulness, dan insurance literacy, serta dianalisis menggunakan PLS-SEM (SmartPLS 4) yang sesuai untuk tujuan pengujian hubungan kausal sekaligus orientasi prediksi [28], [29].

Nama Kegiatan dan bulan pelaksanaan adalah sebagaimana tabel berikut. Untuk mengantisipasi ketepatan waktu pencapaian target luaran, semua proses analisis dan penyusunan artikel akan diselesaikan pada bulan kelima dan penyusunan buku akan diselesaikan pada bulan ketujuh. Dengan revisi pelaksanaan ini, diharapkan akan bisa dicapai keseluruhan hasil penelitian pada akhir tahun.

No	Nama Kegiatan	Bulan											
		1	2	3	4	5	6	7	8	9	10	11	12
1	Review Literatur		x	x									
2	Penyusunan proposal penelitian		x	x									
3	Penyusunan instrumen penelitian			x									
4	Persiapan pengumpulan data penelitian			x									
5	Pengumpulan data penelitian			x	x								
6	Pengolahan data penelitian			x	x								
7	Analisis hasil penelitian				x	x							
8	Penulisan artikel empiris untuk publikasi dan konferensi internasional				x	x							
8	Presentasi pada konferensi internasional								x				
10	Penyusunan Laporan Penelitian											x	
11	Submit artikel ke jurnal internasional bereputasi						x						
12	Penyusunan Buku					x	x	x					

H. DAFTAR PUSTAKA: Penyusunan Daftar Pustaka berdasarkan sistem nomor sesuai dengan urutan pengutipan. Hanya pustaka yang disitasi pada laporan kemajuan yang dicantumkan dalam Daftar Pustaka.

- [1] M. C. Jensen and W. H. Meckling, "Theory of the firm: Managerial behavior, agency costs and ownership structure," *J. financ. econ.*, vol. 3, no. 4, pp. 305–360, 1976, doi: 10.1016/0304-405X(76)90026-X.
- [2] E. F. Fama and M. C. Jensen, "Separation of Ownership and Control," *J. Law Econ.*, vol. 26, no. 2, pp. 301–325, 1983, doi: 10.1086/467037.
- [3] M. Adams and W. Jiang, "Do outside directors influence the performance of risk-trading firms? Evidence from the United Kingdom (UK) insurance industry," *J. Bank. & Financ.*, vol. 64, pp. 36–51, 2016, doi: 10.1016/j.jbankfin.2015.11.018.
- [4] A. Shleifer and R. W. Vishny, "A survey of corporate governance," *J. Finance*, vol. 52, no. 2, pp. 737–783, 1997, doi: 10.1111/j.1540-6261.1997.tb04820.x.
- [5] H. Singu, "Prediction of Bankruptcy of Non-Life Insurance Companies in India-A Study," *Int. J. Appl. Bus. Econ. Res.*, vol. 13, no. 3, pp. 1431–1444, 2015.
- [6] R. BarNiv and R. A. Hershberger, "Classifying Financial Distress in the Life Insurance Industry," *J. Risk Insur.*, vol. 57, no. 1, p. 110, 1990, doi: 10.2307/252927.
- [7] D. Berg, "Bankruptcy prediction by generalized additive models," *Aplimat 2007*, vol. 2007-Janua, no. 2, pp. 323–331, 2007.
- [8] P. L. Brockett, L. L. Golden, J. Jang, and C. Yang, "A comparison of neural network, statistical methods, and variable choice for life insurers' financial distress prediction," *J. Risk Insur.*, vol. 73, no. 3, pp. 397–419, 2006, doi: 10.1111/j.1539-6975.2006.00181.x.
- [9] P. L. Brockett, W. W. Cooper, L. L. Golden, and U. Pitaktong, "A Neural Network Method for Obtaining an Early Warning of Insurer Insolvency," *J. Risk Insur.*, vol. 61, no. 3, p. 402, 1994, doi: 10.2307/253568.
- [10] R. BarNiv and J. B. McDonald, "Identifying Financial Distress in the Insurance Industry: A Synthesis of Methodological and Empirical Issues," *J. Risk Insur.*, vol. 59, no. 4, p. 543, 1992, doi: 10.2307/253344.
- [11] Díaz, Segovia, Fernandez, and del Pozo, "Machine Learning and Statistical Techniques. An Application to the Prediction of Insolvency in Spanish Non-life Insurance Companies," *Int. J. Digit. Account. Res.*, vol. 5, no. 9, pp. 1–45, 2005, doi: 10.4192/1577-8517-v5_1.
- [12] T. Gunarsih, P. A. Prasasti, and S. D. Sari, "Prediksi Peringkat Obligasi Dengan Corporate Governance Perception Index (CGPI) Dan Karakteristik Obligasi," *J. Keuang. dan Perbank.*, vol. 19, no. 1, pp. 52–66, 2015.
- [13] C. Doru, "A NEW MODEL FOR ESTIMATING THE RISK OF BANKRUPTCY OF THE INSURANCE COMPANIES BASED ON THE ARTIFICIAL NEURAL NETWORKS," in *16th International Multidisciplinary Scientific GeoConference SGEM2016, Informatics, Geoinformatics and Remote Sensing, Surveying Geology & Mining Ecology Management (SGEM)*, Jun. 2016, pp. 3–10. doi: 10.5593/SGEM2016/B21/S07.001.
- [14] S. H. Hsiao and T. J. Whang, "A study of financial insolvency prediction model for life insurers," *Expert Syst. Appl.*, vol. 36, no. 3 PART 2, pp. 6100–6107, 2009, doi: 10.1016/j.eswa.2008.07.024.
- [15] a. B. Ibiwoye, A., Ajibola, O. E., & Sogunro, "Artificial Neural Network Model for Predicting Insurance Insolvency," *Int. J. Manag. Bus. Res.*, vol. 2, no. 1, pp. 59–68, 2012.
- [16] A. Kadar Muhammad Masum, M. Abdur Rahman, E. Hoque Bahadur, M. Shamsul Alam, M. Kalim Ullah Chowdhury, and A. Professor, "Prognosticate Bankruptcy: Machine Learning to Convey the Chance of Distress," *Int. J. Adv. Sci. Technol.*, vol. 29, no. 4, pp. 10777–10795, 2020.
- [17] M. K. Severino and Y. Peng, "Machine learning algorithms for fraud prediction in property insurance: Empirical evidence using real-world microdata," *Mach. Learn. with Appl.*, vol. 5, p. 100074, 2021, doi: 10.1016/j.mlwa.2021.100074.
- [18] E. E. Hassan and D. Zhang, "The Usage of Logistic Regression and Artificial Neural Networks for

- Evaluation and Predicting Property-Liability Insurers' Solvency in Egypt," *Data Sci. Financ. Econ.*, vol. 1, no. 3, pp. 215–234, 2021, doi: 10.3934/DSFE.2021012.
- [19] A. Dasilas and A. Rigani, "Machine learning techniques in bankruptcy prediction: A systematic literature review," *Expert Syst. Appl.*, vol. 255, p. 124761, 2024, doi: 10.1016/j.eswa.2024.124761.
 - [20] D. W. Utami, H. E. Atmaja, and H. Hirawati, "The Role of Financial Ratios on the Financial Distress Prediction," *Kinerja*, vol. 25, no. 2, pp. 287–307, 2021, doi: 10.24002/kinerja.v25i2.4661.
 - [21] A. Runis, D. S. Arifin, A. Masud, and U. Kalsum, "The Influence of Liquidity, Leverage, Company Size and Profitability on Financial Distress," *Int. J. Bus. Soc. Sci. Res.*, vol. 2, no. 6, pp. 11–17, 2021, doi: 10.47742/ijbssr.v2n6p2.
 - [22] V. Azalia and Y. Rahayu, "Pengaruh Leverage, Likuiditas, Profitabilitas, dan Ukuran Perusahaan Terhadap Financial Distress," *J. Ilmu dan Ris. Akunt.*, vol. 8, no. 6, pp. 1–16, 2019.
 - [23] D. Anggrainy, M. Maslichah, and D. Sudaryanti, "The Influence of Liquidity, Profitability, and Leverage on Financial Distress Prediction in Manufacturing Companies of the Food and Beverage Sub-Sector Listed in the Indonesia Stock Exchange (IDX)," *e-Jurnal Ilm. Ris. Akunt.*, vol. 13, no. 1, pp. 509–518, 2024.
 - [24] R. A. Rachman, "The Determinants of Financial Distress in Emerging Country: Empirical Evidence from Indonesia," *J. Keuang. dan Perbank.*, vol. 26, no. 4, pp. 735–747, 2022, doi: 10.26905/jkdp.v26i4.7891.
 - [25] S. Darmadi, "Board members' education and firm performance: Evidence from a developing economy," *Int. J. Commer. Manag.*, vol. 23, no. 2, pp. 113–135, 2013, doi: 10.1108/10569211311324911.
 - [26] M. Madyan, R. G. Setyowati, and W. R. Setiawan, "Education level of the board of directors and financial performance of go public banks at the Indonesia Stock Exchange," *J. Manaj. Teor. dan Terap.*, vol. 14, no. 3, pp. 264–279, 2021, doi: 10.20473/jmtt.v14i3.31210.
 - [27] S. Sriwati, V. Verawati, and H. Kurniawan, "The Impact of the Board of Directors' Experience, Education, and Compensation on Indonesian Banks' Financial Performance," *Int. J. Appl. Econ. Bus.*, vol. 3, no. 3, pp. 1545–1556, 2025, doi: 10.24912/ijaeb.v3i3.1545-1556.
 - [28] P. Guenther, M. Guenther, C. M. Ringle, G. Zaefarian, and S. Cartwright, "Improving PLS-SEM use for business marketing research," *Ind. Mark. Manag.*, vol. 111, pp. 127–142, May 2023, doi: 10.1016/j.indmarman.2023.03.010.
 - [29] J. Hair and A. Alamer, "Partial Least Squares Structural Equation Modeling (PLS-SEM) in second language and education research: Guidelines using an applied example," *Res. Methods Appl. Linguist.*, vol. 1, p. 100027, 2022, doi: 10.1016/j.rmal.2022.100027.